

UNIBALSAS
CENTRO UNIVERSITÁRIO DE BALSAS

CARINNE DA SILVA BORGES
ROGÉRIO MOTA DE MELO
JÚLIO CESAR LIMA DOS REIS
JOÃO PEDRO STRASSER SANTOS

IANJOS DE PATAS
Definição do Problema de Dados e Seleção do Conjunto de Dados

1 PROBLEMA DO PROJETO E SOLUÇÃO PROPOSTA

Este trabalho seleciona e avalia uma base pública para apoiar os testes do IAnjos de Patas. A base escolhida é a PetFinder.my mini, com 11.537 registros. A inspeção indica que ela permite testar filtros básicos do catálogo, mas não substitui os dados da ONG nem comprova a compatibilidade comportamental dos animais.

Conforme o trabalho de Inteligência Artificial anexado, o projeto atende à Sociedade Protetora dos Animais Anjos de Patas, em Balsas, Maranhão. O problema é a dificuldade de localizar animais com características correspondentes às preferências dos interessados, em um contexto de informações dispersas e consultas que dependem de publicações ou contato com a organização.

O MVP é um catálogo web com cadastro dos animais e busca em linguagem natural. A IA transforma o texto do usuário em critérios estruturados; o back-end valida os critérios e consulta o banco. O sistema apresenta somente informações cadastradas. Não haverá treinamento de modelo próprio, análise de imagens ou aprovação automática de adoções.

2 NECESSIDADES DE DADOS

Informação necessária	Finalidade no MVP	Cobertura na base mini
Espécie e sexo	Interpretar e aplicar preferências básicas	Type e Gender
Porte e idade	Filtrar características físicas e faixa etária	MaturitySize e Age
Temperamento	Consultar características comportamentais registradas	Sem campo estruturado
Convivência	Filtrar convivência com crianças ou outros animais	Sem campo estruturado
Identificação e situação atual	Distinguir animais e exibir somente disponíveis	Sem ID original ou situação atual
Frases e critérios esperados	Avaliar a interpretação da IA em português	Precisam ser preparados pela equipe

3 COMPARAÇÃO DAS ALTERNATIVAS

Foram consultadas a documentação da competição PetFinder.my, a versão mini distribuída pelo TensorFlow e a base histórica de saídas do Austin Animal Center. A comparação priorizou os atributos necessários à busca, a possibilidade de inspeção e as limitações de uso. Apenas a versão mini foi analisada integralmente nesta etapa.

Alternativa	Adequação ao projeto	Limitação e decisão
PetFinder.my original Kaggle	A documentação técnica relaciona espécie, idade, sexo e porte.	Escopo mais amplo; arquivos e regras da competição exigem verificação própria. Não selecionada nesta etapa.
PetFinder.my mini TensorFlow	CSV com espécie, sexo, porte, idade e descrição; download público verificado.	Não cobre todos os requisitos do MVP. Selecionada para testes parciais e exploração.
Austin Animal Center Histórico 2013 a 2025	Metadados incluem espécie, sexo, idade, raça e desfecho da saída.	Sem coluna de porte, temperamento ou convivência no esquema consultado. Menor aderência à busca proposta.

4 CONJUNTO SELECIONADO E ORIGEM

A base selecionada foi o petfinder-mini.csv, uma versão simplificada de dados da PetFinder.my, plataforma de adoção de animais da Malásia. O arquivo é disponibilizado no pacote petfinder-mini.zip, utilizado em um tutorial oficial do TensorFlow e relacionado à competição original PetFinder.my Adoption Prediction.

O CSV foi baixado e inspecionado em 16 de setembro de 2026. Foram contados 11.537 registros e 15 colunas (formato dos dados: CSV). São registros históricos de perfis; o total não deve ser interpretado como quantidade de animais únicos ou disponíveis atualmente.

Documentação: [TensorFlow — Classify structured data using Keras preprocessing layers.](#)

Download dos dados: [PetFinder mini \(ZIP\).](#)

A escolha considera a correspondência entre os campos e os filtros do MVP. A base é adequada ao objetivo desta etapa por permitir selecionar, compreender e avaliar dados relacionados ao problema e apresentar atributos compatíveis com parte das necessidades do MVP.

5 PRINCIPAIS ATRIBUTOS

A inspeção encontrou os campos abaixo. Os tipos indicam a representação observada no CSV. As categorias estão em inglês e precisarão ser padronizadas para a interface em português.

Atributo	Tipo observado	Significado e uso previsto
Type	Texto categórico	Espécie; filtro principal.
Age	Inteiro	Idade do animal em meses; pode ser utilizada para definição de faixas etárias.
Breed1	Texto categórico	Raça principal; informação complementar.
Gender	Texto categórico	Sexo; filtro principal.
Color1	Texto categórico	Cor principal; atributo complementar.
Color2	Texto categórico	Segunda cor; No Color indica ausência de segunda cor.
MaturitySize	Texto categórico	Porte na maturidade; não equivale necessariamente ao tamanho atual.
FurLength	Texto categórico	Comprimento da pelagem.
Vaccinated	Texto categórico	Informação de vacinação, incluindo Not Sure.
Sterilized	Texto categórico	Informação de castração, incluindo Not Sure.
Health	Texto categórico	Condição de saúde declarada no cadastro.
Fee	Inteiro	Taxa de adoção da fonte; fora dos filtros essenciais do MVP.
Description	Texto livre	Descrição do perfil; exige leitura e validação antes de extrair atributos.
PhotoAmt	Inteiro	Quantidade de fotos; não contém as próprias imagens.
AdoptionSpeed	Inteiro categórico	Classes históricas de tempo até a adoção, de 0 a 4; fora do objetivo de busca.

AdoptionSpeed não será usado como indicador de disponibilidade atual nem como avaliação de adequação a uma família. A finalidade do projeto é recuperar perfis segundo

informações cadastradas, e não prever quais animais serão adotados primeiro.

6 AVALIAÇÃO PRELIMINAR DA QUALIDADE

A análise foi realizada pelo script `src/inspecionar_dados.py`, incluído no pacote. O procedimento contou registros e colunas, verificou campos vazios, linhas integralmente repetidas, categorias e intervalos numéricos. O arquivo original não foi corrigido ou reduzido. Os resultados completos estão em `reports/inspecao.json`.

Verificação	Resultado observado	Interpretação inicial
Espécies	6.601 cães e 4.936 gatos	Há cobertura das duas espécies do MVP.
Sexo	6.466 Female e 5.071 Male	Permite testar os dois valores presentes.
Porte	8.016 Medium; 2.480 Small; 1.041 Large	Distribuição concentrada no porte médio.
Campos vazios	9 em Description; zero nas outras 14 colunas	Ausência de texto em parte dos perfis.
Linhas repetidas	143 ocorrências excedentes	Igualdade nas 15 colunas; não prova que seja o mesmo animal.
Valores desconhecidos	1.515 Not Sure em Vaccinated; 1.343 em Sterilized	Não devem ser convertidos em resposta negativa.
Idade numérica	Mínimo 0; máximo 255; 78 registros com zero	Extremos exigem avaliação; não foram classificados automaticamente como erro.
Valores numéricos	Sem negativos em Age, Fee e PhotoAmt	Isso não comprova a exatidão dos cadastros.

A repetição foi calculada preservando a primeira ocorrência de cada linha idêntica. Como a versão mini não possui identificador original, remover automaticamente as 143 ocorrências pode excluir perfis distintos com o mesmo conteúdo. A decisão de tratamento será documentada na próxima etapa.

A ausência de campos vazios em várias colunas não significa qualidade perfeita. É necessário avaliar valores desconhecidos, definições dos campos, concentração das categorias e adequação ao contexto da ONG. Também não foi realizada leitura manual de todas as descrições.

7 CONTRIBUIÇÃO PARA O MVP E LIMITAÇÕES

A base pode apoiar a modelagem dos atributos, a padronização de categorias e a conferência das consultas. Por exemplo, uma busca de teste por “uma gata de porte pequeno” pode ser convertida em Type = Cat, Gender = Female e MaturitySize = Small. Os resultados devem atender simultaneamente aos três critérios. Esse exemplo é um cenário proposto; a interpretação por IA ainda não foi avaliada nesta etapa.

A validação futura deve separar duas tarefas: verificar se a IA interpreta corretamente a frase e verificar se a consulta retorna somente registros que atendem aos critérios. Para a primeira tarefa, a equipe preparará frases em português e respostas esperadas revisadas por pessoas. A base de animais, sozinha, não fornece esse conjunto de avaliação.

O documento de IA estabelece uma meta de pelo menos 80% de concordância com a avaliação humana nos cenários de teste. Esta seleção de dados não demonstra que a meta foi atingida. Qualquer atributo inventado ou informação desconhecida tratada como compatibilidade deverá ser registrado como falha.

7.1 Limitações identificadas

Temperamento e convivência não possuem colunas próprias. Uma descrição livre pode mencionar comportamento, mas isso não garante informação completa, atual ou validada. Não se deve inferir convivência com crianças a partir de raça, porte ou aparência. Esses requisitos dependerão de cadastros confirmados pela ONG.

A base é histórica e estrangeira. Seus perfis não representam a população da Anjos de Patas, e diferenças de categorias, idioma e contexto limitam a transferência dos resultados. Os dados externos serão usados apenas em ambiente de estudo, sem divulgação como animais disponíveis da ONG.

A versão mini já é uma simplificação da fonte original. A remoção de atributos limita a rastreabilidade dos perfis e a avaliação da representatividade. Também não há identificador original nem situação atual; um ID técnico criado para testes identificará somente a linha importada.

A seleção é adequada para exploração e testes dos filtros básicos, mas insuficiente para validar todo o MVP. A continuidade exige complementar os dados com registros autorizados da ONG e cenários de linguagem natural. A base poderá ser substituída se essas limitações impedirem os objetivos das próximas etapas.

8 ORGANIZAÇÃO DO REPOSITÓRIO

O repositório deve reunir o trabalho original de IA, este relatório, os scripts e o resultado da inspeção. O README principal identifica a equipe e orienta a reprodução. A pasta data contém o endereço exato da fonte e instruções de obtenção.

O README do pacote da fonte menciona permissão para o tutorial do TensorFlow, mas não apresenta licença explícita para redistribuição por terceiros. Por isso, o CSV não foi incluído nesta entrega. A ausência de licença confirmada não é apresentada como proibição definitiva: a equipe deverá verificar as condições antes de republicar o arquivo. A licença da página ou do código do tutorial não deve ser presumida como licença dos dados.

Para reproduzir a análise, execute `python src/obter_dados.py` e, em seguida, `python src/inspecionar_dados.py data/petfinder-mini.csv`. Os scripts utilizam somente a biblioteca padrão do Python 3.

REFERÊNCIAS

BORGES, Carinne da Silva; MELO, Rogério Mota de; REIS, Júlio Cesar Lima dos; SANTOS, João Pedro Strasser. **IAijos de Patas: assistente inteligente para apoio à busca de animais para adoção**. Balsas: UNIBALSAS, 2026. Trabalho da disciplina de Inteligência Artificial.

CITY OF AUSTIN. Austin Animal Center Outcomes (10/01/2013 to 05/05/2025).

Austin: City of Austin, [s. d.]. Conjunto de dados. Disponível em: <https://data.austintexas.gov/widgets/9t4d-g238>. Acesso em: 16 set. 2026.

KAGGLE; PETFINDER.MY. PetFinder.my Adoption Prediction. Kaggle, 2019.

Conjunto de dados da competição PetFinder.my Adoption Prediction. Disponível em: <https://www.kaggle.com/competitions/petfinder-adoption-prediction/data>. Acesso em: 16 set. 2026.

TENSORFLOW. Classify structured data using Keras preprocessing layers. [s. d.].

Disponível em: https://www.tensorflow.org/tutorials/structured_data/preprocessing_layers. Acesso em: 16 set. 2026.

TENSORFLOW DATASETS. Pet Finder. [s. d.]. Disponível em:

https://www.tensorflow.org/datasets/catalog/pet_finder. Acesso em: 16 set. 2026.