UNIBALSAS CENTRO UNIVERSITÁRIO DE BALSAS

CARINNE DA SILVA BORGES
ROGÉRIO MOTA DE MELO
JÚLIO CESAR LIMA DOS REIS
JOÃO PEDRO STRASSER SANTOS

IANJOS DE PATAS

Documento Técnico Versão 2.0

Balsas MA
2026

CARINNE DA SILVA BORGES
ROGÉRIO MOTA DE MELO
JÚLIO CESAR LIMA DOS REIS
JOÃO PEDRO STRASSER SANTOS

IANJOS DE PATAS

Documento Técnico Versão 2.0

Trabalho apresentado à disciplina de Big Data e Ciência de Dados do curso de Análise e Desenvolvimento de Sistemas do Centro Universitário de Balsas UNIBALSAS.

Balsas MA
2026

SUMÁRIO

1 PROBLEMA DO PROJETO E SOLUÇÃO PROPOSTA 3

2 NECESSIDADES DE DADOS 4

3 COMPARAÇÃO DAS ALTERNATIVAS 5

4 CONJUNTO SELECIONADO E ORIGEM 6

5 PRINCIPAIS ATRIBUTOS 7

6 AVALIAÇÃO PRELIMINAR DA QUALIDADE 8

7 CONTRIBUIÇÃO PARA O MVP E LIMITAÇÕES 9

7.1 Limitações identificadas 9

8 ORGANIZAÇÃO DO REPOSITÓRIO 10

9 Continuidade da TED 02 com a PetFinder mini 11

10 Método e reprodução 12

11 Tratamentos e justificativas 13

12 Estatísticas e possíveis valores extremos 14

13 Distribuições de espécie e porte 15

14 Distribuições de idade e cuidados 16

15 Relações entre as variáveis 17

16 Contribuições para o MVP e conclusão 18

17 Arquivos e execução 19

REFERÊNCIAS 20

1 PROBLEMA DO PROJETO E SOLUÇÃO PROPOSTA

Este trabalho seleciona e avalia uma base pública para apoiar os testes do IAnjos de Patas. A base escolhida é a PetFinder.my mini, com 11.537 registros. A inspeção indica que ela permite testar filtros básicos do catálogo, mas não substitui os dados da ONG nem comprova a compatibilidade comportamental dos animais.

Conforme o trabalho de Inteligência Artificial anexado, o projeto atende à Sociedade Protetora dos Animais Anjos de Patas, em Balsas, Maranhão. O problema é a dificuldade de localizar animais com características correspondentes às preferências dos interessados, em um contexto de informações dispersas e consultas que dependem de publicações ou contato com a organização.

O MVP é um catálogo web com cadastro dos animais e busca em linguagem natural. A IA transforma o texto do usuário em critérios estruturados; o back-end valida os critérios e consulta o banco. O sistema apresenta somente informações cadastradas. No escopo do MVP institucional, não está previsto treinamento de modelo próprio, análise de imagens ou aprovação automática de adoções. O classificador acadêmico da TED 03 é um experimento complementar, sem integração ao MVP.

2 NECESSIDADES DE DADOS

Tabela 1 - Informação necessária / Finalidade no MVP / Cobertura na base mini

Informação necessária	Finalidade no MVP	Cobertura na base mini
Espécie e sexo	Interpretar e aplicar preferências básicas	Type e Gender
Porte e idade	Filtrar características físicas e faixa etária	MaturitySize e Age
Temperamento	Consultar características comportamentais registradas	Sem campo estruturado
Convivência	Filtrar convivência com crianças ou outros animais	Sem campo estruturado
Identificação e situação atual	Distinguir animais e exibir somente disponíveis	Sem ID original ou situação atual
Frases e critérios esperados	Avaliar a interpretação da IA em português	Precisam ser preparados pela equipe

Fonte: elaboração da equipe com base nos dados e documentos do projeto (2026).

3 COMPARAÇÃO DAS ALTERNATIVAS

Foram consultadas a documentação da competição PetFinder.my, a versão mini distribuída pelo TensorFlow e a base histórica de saídas do Austin Animal Center. A comparação priorizou os atributos necessários à busca, a possibilidade de inspeção e as limitações de uso. Apenas a versão mini foi analisada integralmente nesta etapa.

Tabela 2 - Alternativa / Adequação ao projeto / Limitação e decisão

Alternativa	Adequação ao projeto	Limitação e decisão
PetFinder.my originalKaggle	A documentação técnica relaciona espécie, idade, sexo e porte.	Escopo mais amplo; arquivos e regras da competição exigem verificação própria. Não selecionada nesta etapa.
PetFinder.my miniTensorFlow	CSV com espécie, sexo, porte, idade e descrição; download público verificado.	Não cobre todos os requisitos do MVP. Selecionada para testes parciais e exploração.
Austin Animal CenterHistórico 2013 a 2025	Metadados incluem espécie, sexo, idade, raça e desfecho da saída.	Sem coluna de porte, temperamento ou convivência no esquema consultado. Menor aderência à busca proposta.

Fonte: elaboração da equipe com base nos dados e documentos do projeto (2026).

4 CONJUNTO SELECIONADO E ORIGEM

A base selecionada foi o petfinder-mini.csv, uma versão simplificada de dados da PetFinder.my, plataforma de adoção de animais da Malásia. O arquivo é disponibilizado no pacote petfinder-mini.zip, utilizado em um tutorial oficial do TensorFlow e relacionado à competição original PetFinder.my Adoption Prediction.

O CSV foi baixado e inspecionado em 16 de setembro de 2026. Foram contados 11.537 registros e 15 colunas (formato dos dados: CSV). São registros históricos de perfis; o total não deve ser interpretado como quantidade de animais únicos ou disponíveis atualmente.

Documentação: TensorFlow — Classify structured data using Keras preprocessing layers.Download dos dados: PetFinder mini (ZIP).

A escolha considera a correspondência entre os campos e os filtros do MVP. A base é adequada ao objetivo desta etapa por permitir selecionar, compreender e avaliar dados relacionados ao problema e apresentar atributos compatíveis com parte das necessidades do MVP.

5 PRINCIPAIS ATRIBUTOS

A inspeção encontrou os campos abaixo. Os tipos indicam a representação observada no CSV. As categorias estão em inglês e precisarão ser padronizadas para a interface em português.

Tabela 3 - Atributo / Tipo observado / Significado e uso previsto

Atributo	Tipo observado	Significado e uso previsto
Type	Texto categórico	Espécie; filtro principal.
Age	Inteiro	Idade do animal em meses; pode ser utilizada para definição de faixas etárias.
Breed1	Texto categórico	Raça principal; informação complementar.
Gender	Texto categórico	Sexo; filtro principal.
Color1	Texto categórico	Cor principal; atributo complementar.
Color2	Texto categórico	Segunda cor; No Color indica ausência de segunda cor.
MaturitySize	Texto categórico	Porte na maturidade; não equivale necessariamente ao tamanho atual.
FurLength	Texto categórico	Comprimento da pelagem.
Vaccinated	Texto categórico	Informação de vacinação, incluindo Not Sure.
Sterilized	Texto categórico	Informação de castração, incluindo Not Sure.
Health	Texto categórico	Condição de saúde declarada no cadastro.
Fee	Inteiro	Taxa de adoção da fonte; fora dos filtros essenciais do MVP.
Description	Texto livre	Descrição do perfil; exige leitura e validação antes de extrair atributos.
PhotoAmt	Inteiro	Quantidade de fotos; não contém as próprias imagens.
AdoptionSpeed	Inteiro categórico	Classes históricas de tempo até a adoção, de 0 a 4; fora do objetivo de busca.

Fonte: elaboração da equipe com base nos dados e documentos do projeto (2026).

AdoptionSpeed não será usado como indicador de disponibilidade atual nem como avaliação de adequação a uma família. A finalidade do projeto é recuperar perfis segundo informações cadastradas, e não prever quais animais serão adotados primeiro.

6 AVALIAÇÃO PRELIMINAR DA QUALIDADE

A análise foi realizada pelo script src/inspecionar_dados.py, incluído no pacote. O procedimento contou registros e colunas, verificou campos vazios, linhas integralmente repetidas, categorias e intervalos numéricos. O arquivo original não foi corrigido ou reduzido. Os resultados completos estão em reports/inspecao.json.

Tabela 4 - Verificação / Resultado observado / Interpretação inicial

Verificação	Resultado observado	Interpretação inicial
Espécies	6.601 cães e 4.936 gatos	Há cobertura das duas espécies do MVP.
Sexo	6.466 Female e 5.071 Male	Permite testar os dois valores presentes.
Porte	8.016 Medium; 2.480 Small; 1.041 Large	Distribuição concentrada no porte médio.
Campos vazios	9 em Description; zero nas outras 14 colunas	Ausência de texto em parte dos perfis.
Linhas repetidas	143 ocorrências excedentes	Igualdade nas 15 colunas; não prova que seja o mesmo animal.
Valores desconhecidos	1.515 Not Sure em Vaccinated; 1.343 em Sterilized	Não devem ser convertidos em resposta negativa.
Idade numérica	Mínimo 0; máximo 255; 78 registros com zero	Extremos exigem avaliação; não foram classificados automaticamente como erro.
Valores numéricos	Sem negativos em Age, Fee e PhotoAmt	Isso não comprova a exatidão dos cadastros.

Fonte: elaboração da equipe com base nos dados e documentos do projeto (2026).

A repetição foi calculada preservando a primeira ocorrência de cada linha idêntica. Como a versão mini não possui identificador original, remover automaticamente as 143 ocorrências pode excluir perfis distintos com o mesmo conteúdo. A decisão de tratamento será documentada na próxima etapa.

A ausência de campos vazios em várias colunas não significa qualidade perfeita. É necessário avaliar valores desconhecidos, definições dos campos, concentração das categorias e adequação ao contexto da ONG. Também não foi realizada leitura manual de todas as descrições.

7 CONTRIBUIÇÃO PARA O MVP E LIMITAÇÕES

A base pode apoiar a modelagem dos atributos, a padronização de categorias e a conferência das consultas. Por exemplo, uma busca de teste por “uma gata de porte pequeno” pode ser convertida em Type = Cat, Gender = Female e MaturitySize = Small. Os resultados devem atender simultaneamente aos três critérios. Esse exemplo é um cenário proposto; a interpretação por IA ainda não foi avaliada nesta etapa.

A validação futura deve separar duas tarefas: verificar se a IA interpreta corretamente a frase e verificar se a consulta retorna somente registros que atendem aos critérios. Para a primeira tarefa, a equipe preparará frases em português e respostas esperadas revisadas por pessoas. A base de animais, sozinha, não fornece esse conjunto de avaliação.

O documento de IA estabelece uma meta de pelo menos 80% de concordância com a avaliação humana nos cenários de teste. Esta seleção de dados não demonstra que a meta foi atingida. Qualquer atributo inventado ou informação desconhecida tratada como compatibilidade deverá ser registrado como falha.

7.1 Limitações identificadas

Temperamento e convivência não possuem colunas próprias. Uma descrição livre pode mencionar comportamento, mas isso não garante informação completa, atual ou validada. Não se deve inferir convivência com crianças a partir de raça, porte ou aparência. Esses requisitos dependerão de cadastros confirmados pela ONG.

A base é histórica e estrangeira. Seus perfis não representam a população da Anjos de Patas, e diferenças de categorias, idioma e contexto limitam a transferência dos resultados. Os dados externos serão usados apenas em ambiente de estudo, sem divulgação como animais disponíveis da ONG.

A versão mini já é uma simplificação da fonte original. A remoção de atributos limita a rastreabilidade dos perfis e a avaliação da representatividade. Também não há identificador original nem situação atual; um ID técnico criado para testes identificará somente a linha importada.

A seleção é adequada para exploração e testes dos filtros básicos, mas insuficiente para validar todo o MVP. A continuidade exige complementar os dados com registros autorizados da ONG e cenários de linguagem natural. A base poderá ser substituída se essas limitações impedirem os objetivos das próximas etapas.

8 ORGANIZAÇÃO DO REPOSITÓRIO

O repositório reúne os documentos das etapas, os scripts e os resultados de inspeção, preparação e modelagem. O README identifica a equipe, as dependências e as instruções de reprodução. Os manifestos registram a origem e a identificação dos dados.

O pacote local contém os CSVs para reprodução privada; eles são ignorados pelo Git. A redistribuição pública depende de confirmação das condições de uso. Na ausência dessa confirmação, o repositório disponibiliza a fonte, os manifestos e os scripts para obtenção e preparação, sem presumir que a licença do tutorial se aplica aos dados.

Para reproduzir a inspeção inicial, execute python src/obter_dados.py e python src/inspecionar_dados.py data/raw/petfinder-mini.csv. Esses dois scripts usam a biblioteca padrão. Para as TEDs 02 e 03, instale as dependências do requirements.txt e execute src/ted02.py e src/ted03.py, conforme o README.

9 Continuidade da TED 02 com a PetFinder mini

Esta versão mantém a PetFinder.my mini selecionada na TED 01. A alternativa US Shelter Dogs foi descartada para esta entrega. As seções anteriores foram preservadas como histórico; as seções a seguir registram a preparação e a análise realizadas nesta etapa. Nenhum resultado da planilha bigdata.xlsx é utilizado nesta análise.

O objetivo é preparar os registros para estudar filtros e futuras consultas em linguagem natural do IAnjos de Patas. A exploração não mede desempenho da IA e não comprova compatibilidade comportamental. O conjunto histórico da Malásia não representa os animais atualmente atendidos pela ONG em Balsas.

10 Método e reprodução

O arquivo petfinder-mini.csv foi obtido do mesmo endereço do TensorFlow registrado na TED 01. A rotina src/ted02.py lê o CSV, inspeciona categorias e valores numéricos, aplica tratamentos conservadores, exporta tabelas e gera seis gráficos. O notebook chama essa mesma rotina. Frequências incluem todos os registros; a sensibilidade à repetição é apresentada separadamente.

O SHA-256 do arquivo bruto, que identifica exatamente os bytes utilizados, está em data/manifesto_ted02.json. A coluna linha_origem indica a posição lógica no CSV, contando o cabeçalho; não é um identificador de animal. A base original permanece inalterada.

Tabela 5 - Verificação / Resultado

Verificação	Resultado
Registros e colunas originais	11.537 e 15
Linhas idênticas excedentes	143
Descrições vazias	9
Idades iguais a zero	78
Perfis sem fotos registradas	235
Valores inválidos nos domínios verificados	0

Fonte: elaboração da equipe com base nos dados e documentos do projeto (2026).

Zero inválidos refere-se às regras explicitadas no código, não à garantia de que todos os dados estejam corretos. Raças, cores e descrições não passaram por validação externa individual.

11 Tratamentos e justificativas

Descrições: foram retirados espaços nas extremidades de 127 textos. As nove descrições vazias ficaram ausentes e foram sinalizadas em descricao_ausente. Não foram criadas descrições fictícias. O restante do conteúdo textual foi preservado, sem tradução automática ou tentativa de inferir comportamento.

Duplicatas: as 143 ocorrências excedentes foram marcadas em duplicata_excedente e mantidas. Como a versão mini não tem ID original, linhas iguais podem corresponder a perfis distintos. A contagem é realizada nas 15 colunas originais antes da normalização. As estatísticas principais descrevem registros, não animais únicos.

Como análise de sensibilidade, recalcularam-se as proporções de espécie, porte e vacinação após retirar apenas as ocorrências excedentes. A maior variação absoluta nessas proporções foi de 0,46 ponto percentual. Isso indica efeito pequeno nesses resumos, mas não resolve a identidade dos perfis.

Categorias: Yes, No e Not Sure foram preservadas. Not Sure significa informação não confirmada e não deve virar No. A tradução para português foi aplicada nos gráficos; os nomes e categorias da base foram mantidos para facilitar a comparação com a TED 01. As categorias foram verificadas contra os domínios observados e documentados no código.

Números: Age, Fee, PhotoAmt e AdoptionSpeed foram convertidos e verificados. Não foram encontrados valores negativos ou inválidos nas regras aplicadas. Age representa meses; zero foi mantido, pois pode refletir idade inferior a um mês ou imprecisão do cadastro. A interpretação individual não foi confirmada.

Atributos: nenhuma das 15 colunas originais foi removida. AdoptionSpeed é uma categoria de resultado histórico e fica fora dos filtros de compatibilidade do MVP; calcular média desse código não teria interpretação adequada. Fee não foi convertido em reais. PhotoAmt informa quantidade, mas não fornece os arquivos das fotos.

A base tratada tem 11.537 registros e 21 colunas: as 15 originais e seis auxiliares — linha_origem, duplicata_excedente, descricao_ausente, atipico_Age, atipico_Fee e atipico_PhotoAmt. Nenhuma linha foi excluída. O CSV exportado foi reaberto e conferido quanto a dimensões e sequência de linhas.

12 Estatísticas e possíveis valores extremos

Tabela 6 - Variável / Média / Mediana / Desvio padrão / Mínimo / Máximo

Variável	Média	Mediana	Desvio padrão	Mínimo	Máximo
Age	11,74	4,00	19,32	0,00	255,00
Fee	23,96	0,00	80,02	0,00	2000,00
PhotoAmt	3,61	3,00	3,15	0,00	30,00

Fonte: elaboração da equipe com base nos dados e documentos do projeto (2026).

A idade média é de 11,74 meses, mas a mediana é de 4 meses. Essa diferença indica concentração em idades baixas e uma cauda de animais mais velhos. Assim, a mediana complementa a média e evita descrever a base apenas por um valor influenciado pelos extremos.

A mediana de Fee é zero e a média é 23,96 na unidade da fonte. A maior parte dos registros não tem cobrança registrada. A quantidade de fotos tem mediana de 3 e máximo de 30. Esses campos ajudam a compreender a base, mas não comprovam qualidade do perfil ou probabilidade de adoção.

Tabela 7 - Variável / Limite superior IQR / Sinalizados

Variável	Limite superior IQR	Sinalizados
Age	27,00	1340
Fee	0,00	1965
PhotoAmt	9,50	565

Fonte: elaboração da equipe com base nos dados e documentos do projeto (2026).

Foi usada a regra exploratória de 1,5 vezes o intervalo interquartil: abaixo de Q1 − 1,5 × IQR ou acima de Q3 + 1,5 × IQR. O resultado é uma sinalização estatística, não um diagnóstico de erro. Todos esses valores foram mantidos e marcados para revisão.

Em Age, 1.340 registros estão acima de 27 meses. O máximo é 255 meses, cerca de 21 anos e 3 meses: requer conferência na origem, mas não foi considerado impossível automaticamente. Em PhotoAmt, 565 valores ultrapassam 9,5 fotos.

Em Fee, Q1 e Q3 são zero. Por isso, a regra marca todos os 1.965 valores positivos. Excluir esses casos eliminaria precisamente os registros com cobrança. Essa limitação do IQR justifica preservar os dados e interpretar a distribuição antes de decidir qualquer exclusão.

13 Distribuições de espécie e porte

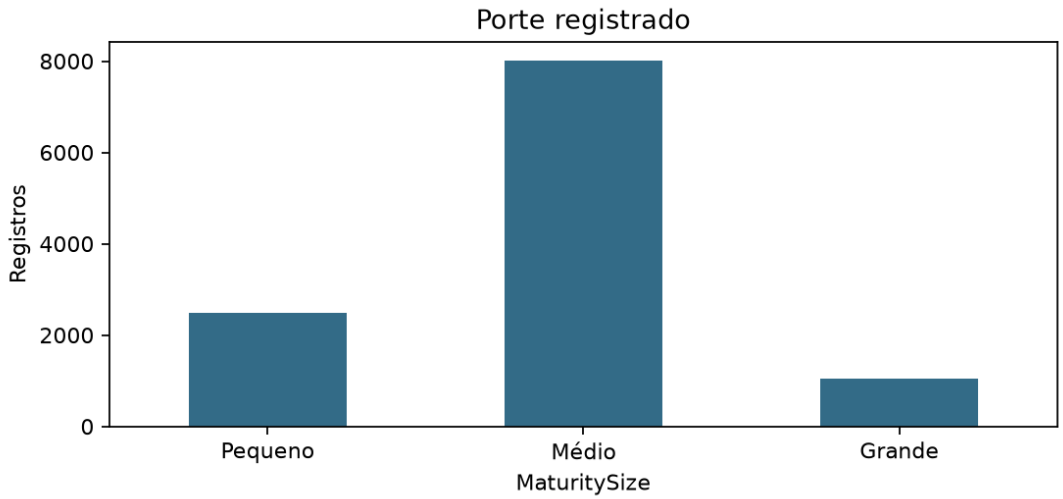
Figura 1 Distribuição por espécie



Fonte: elaboração da equipe a partir da PetFinder.my mini (2026).

A base contém 6.601 registros de cães (57,22%) e 4.936 de gatos (42,78%). Ambas as espécies podem ser usadas nos testes de filtros do MVP. Essa proporção descreve a amostra estrangeira, não a população da ONG.

Figura 2 Distribuição por porte

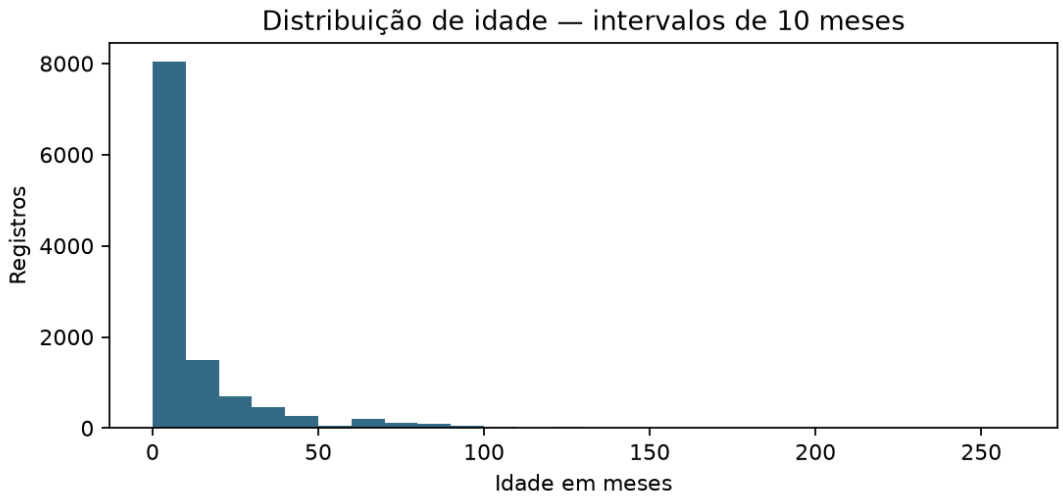


Fonte: elaboração da equipe a partir da PetFinder.my mini (2026).

O porte médio reúne 8.016 registros (69,48%), seguido por 2.480 pequenos e 1.041 grandes. Os testes devem incluir as três categorias, evitando avaliar a busca apenas no grupo mais frequente. Porte não comprova adequação a apartamento ou temperamento.

14 Distribuições de idade e cuidados

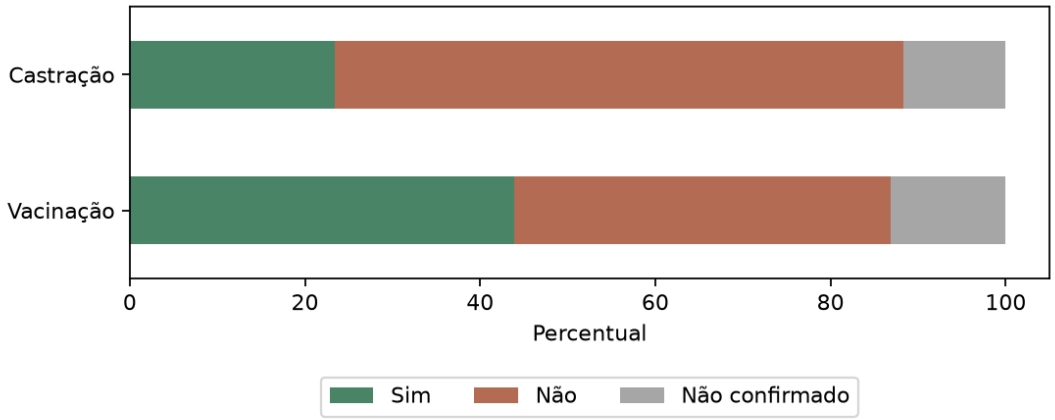
Figura 3 Idade em meses



Fonte: elaboração da equipe a partir da PetFinder.my mini (2026).

O histograma usa intervalos iguais de 10 meses. A concentração em idades baixas e a cauda longa reforçam a diferença entre média e mediana. Para uma busca como “até 12 meses”, o MVP deverá comparar valores numéricos; classificações como filhote e adulto exigem regras explícitas.

Figura 4 Vacinação e castração

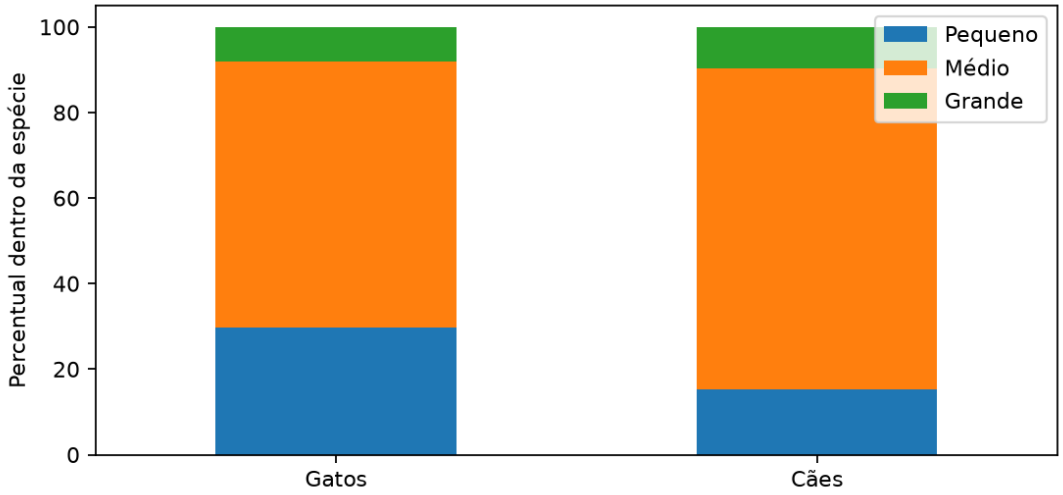


Fonte: elaboração da equipe a partir da PetFinder.my mini (2026).

A vacinação tem 5.060 respostas Yes, 4.962 No e 1.515 Not Sure (13,13% não confirmados). A castração tem 2.697 Yes, 7.497 No e 1.343 Not Sure (11,64%). O sistema deverá preservar a diferença entre resposta negativa e informação desconhecida.

15 Relações entre as variáveis

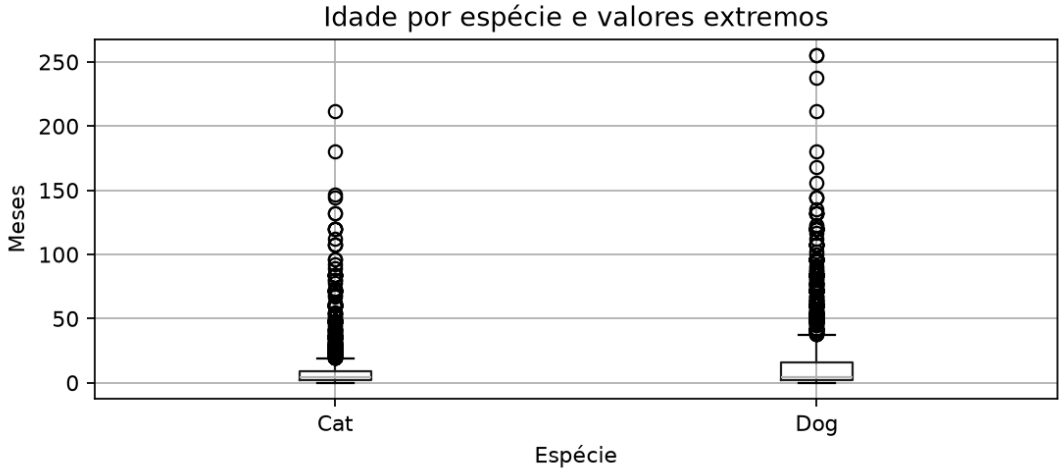
Figura 5 Porte dentro de cada espécie



Fonte: elaboração da equipe a partir da PetFinder.my mini (2026).

O porte médio corresponde a 62,05% dos registros de gatos e 75,03% dos cães. Os percentuais são calculados dentro de cada espécie. Esse cruzamento orienta testes combinados, como “gata pequena”, mas não indica causa nem compatibilidade comportamental.

Figura 6 Idade por espécie



Fonte: elaboração da equipe a partir da PetFinder.my mini (2026).

A mediana de idade é 4,00 meses entre gatos e 4,00 entre cães. Os pontos além dos limites dos boxplots indicam extremos estatísticos dentro de cada grupo. Os limiares por grupo podem diferir da regra global do relatório. A comparação não demonstra que uma espécie é adotada mais rapidamente.

16 Contribuições para o MVP e conclusão

A análise indica que a base permite testar consultas por espécie, sexo, idade, porte, vacinação e castração. Por exemplo, “quero uma gata pequena” pode ser traduzido em Type = Cat, Gender = Female e MaturitySize = Small. O resultado esperado é o conjunto de linhas que satisfaz os três critérios; esta etapa ainda não avaliou a interpretação da frase por IA.

A PetFinder mini não tem campos estruturados de convivência com crianças, cães ou gatos. Portanto, a análise não apresenta percentuais de convivência e não oferece confirmação para uma consulta que exija esse comportamento. Essa informação deverá vir de cadastros verificados pela ONG. Não deve ser deduzida de raça, porte ou sexo.

As principais decisões para o MVP são manter filtros básicos verificáveis, representar explicitamente informações não confirmadas, permitir perfis sem descrição ou fotos e criar testes com categorias frequentes e menos frequentes. O ID técnico serve somente à rastreabilidade da importação.

Limitações: registros históricos e estrangeiros; ausência de ID original e de disponibilidade atual; descrições sem validação individual; possíveis repetições e extremos preservados. As frequências não devem ser generalizadas para Balsas. A análise não mede causalidade, sucesso de adoção ou acurácia da busca em linguagem natural.

A TED 02 preservou a base selecionada na TED 01 e produziu uma versão rastreável com tratamentos justificados. A próxima etapa poderá definir frases em português e resultados esperados para avaliar a interpretação da IA e a aplicação dos filtros. Os documentos e resultados anteriores baseados em US Shelter Dogs não devem ser usados como entrega desta versão.

17 Arquivos e execução

Execute src/ted02.py conforme o README. O arquivo tratado fica em data/processed/petfinder_mini_tratado.csv; tabelas e gráficos ficam em reports/TED02. Os scripts e documentos da TED 01 foram preservados. O notebook notebooks/TED02/TED02_Petfinder.ipynb usa a mesma rotina. Não envie a pasta .venv ao Git.

REFERÊNCIAS

BORGES, Carinne da Silva; MELO, Rogério Mota de; REIS, Júlio Cesar Lima dos; SANTOS, João Pedro Strasser. **IAnjos de Patas**: assistente inteligente para apoio à busca de animais para adoção. Balsas: UNIBALSAS, 2026. Trabalho da disciplina de Inteligência Artificial.

CITY OF AUSTIN. **Austin Animal Center Outcomes** (10/01/2013 to 05/05/2025). Austin: City of Austin, [s. d.]. Conjunto de dados. Disponível em: https://data.austintexas.gov/widgets/9t4d-g238. Acesso em: 16 set. 2026.

KAGGLE; PETFINDER.MY. **PetFinder.my Adoption Prediction**. [S. l.]: Kaggle, 2019. Conjunto de dados. Disponível em: https://www.kaggle.com/competitions/petfinder-adoption-prediction/data. Acesso em: 16 set. 2026.

TENSORFLOW DATASETS. **Pet Finder**. [S. l.], [s. d.]. Disponível em: https://www.tensorflow.org/datasets/catalog/pet_finder. Acesso em: 16 set. 2026.

TENSORFLOW. **Classify structured data using Keras preprocessing layers**. [S. l.], [s. d.]. Disponível em: https://www.tensorflow.org/tutorials/structured_data/preprocessing_layers. Acesso em: 16 set. 2026.

TENSORFLOW. **PetFinder mini**: dados e README do pacote. [S. l.], [s. d.]. Disponível em: https://storage.googleapis.com/download.tensorflow.org/data/petfinder-mini.zip. Acesso em: 16 set. 2026.